

Ứng dụng Feature Engineering và kiến trúc Stacking Ensemble trong dự đoán thể loại âm nhạc

Phạm Văn Tuấn, Nguyễn Thái Vinh, Đặng Nhật Đức,
Võ Văn Tuấn

Khoa Công nghệ thông tin, Trường Đại học Sài Gòn

Ngày 2 tháng 12 năm 2025

Tóm tắt nội dung

Trong kỷ nguyên số hóa âm nhạc, bài toán Phân loại thể loại âm nhạc đóng vai trò then chốt trong việc vận hành các hệ thống gợi ý và quản lý kho dữ liệu số. Tuy nhiên, sự phức tạp trong cấu trúc âm thanh và sự mơ hồ giữa các ranh giới thể loại đặt ra những thách thức lớn về độ chính xác. Nghiên cứu này trình bày một khung làm việc (*framework*) toàn diện, tích hợp các kỹ thuật Tiền xử lý dữ liệu, Kỹ thuật tạo đặc trưng (*Feature Engineering*) dựa trên miền tri thức, và Chiến lược tối ưu hóa mô hình đa tầng. Thông qua việc phân tích sâu bộ dữ liệu Kaggle, chúng tôi đề xuất các biến đổi đặc trưng mới như *Phân loại lời nói* và *Tần suất nghệ sĩ* nhằm nắm bắt các đặc tính tiềm ẩn của bài hát. Kết quả thực nghiệm trên 5 thuật toán học máy tiên tiến (XGBoost, CatBoost, LightGBM, Random Forest, Extra Trees) cho thấy sự cải thiện rõ rệt sau khi tinh chỉnh tham số. Đặc biệt, mô hình **Stacking Ensemble** với kiến trúc hai cấp độ đã đạt độ chính xác kiểm định chéo là **58.45%**, vượt trội so với các mô hình đơn lẻ tốt nhất, khẳng định tính hiệu quả của phương pháp đề xuất.

Từ khóa: Phân loại âm nhạc, Feature Engineering, Stacking Ensemble, XGBoost, CatBoost, Học máy.

1 Giới thiệu

Âm nhạc là một thành phần không thể thiếu trong đời sống hiện đại và trở thành trọng tâm của nhiều hệ thống công nghệ, đặc biệt là các nền tảng phát nhạc trực tuyến như Spotify, Apple Music hay YouTube Music. Các nền tảng này đều dựa trên khả năng phân loại và phân tích âm nhạc để gợi ý nội dung phù hợp cho người dùng. Việc phân loại thể loại âm nhạc không chỉ giúp tổ chức dữ liệu dễ dàng hơn mà còn đóng vai trò trung tâm trong các thuật toán gợi ý và hệ thống tìm kiếm. Tuy nhiên, việc phân loại tự động thể loại của một bài hát lại là thách thức lớn do sự chồng lấn đặc điểm giữa các thể loại, sự đa dạng về cấu trúc âm nhạc cũng như chất lượng bản thu.

Khác với bài toán phân loại văn bản hay ảnh, dữ liệu âm nhạc có tính liên tục theo thời gian và chứa nhiều chiều đặc trưng phức tạp. Một bài hát pop có thể mang những thuộc tính giống nhạc dance, trong khi một bản nhạc acoustic lại có nhiều điểm tương đồng với folk hoặc indie. Bên cạnh đó, các đặc trưng âm thanh thu được có thể chịu ảnh hưởng của phong cách phối khí, kỹ thuật thu âm, cũng như cảm quan thẩm mỹ trong quá trình sản xuất. Tất cả những yếu tố này đặt ra yêu cầu cần có một phương pháp xử lý dữ liệu chặt chẽ và có khả năng khai thác tốt mối quan hệ giữa các đặc trưng âm học.

Trong báo cáo này, chúng tôi tiếp cận bài toán phân loại thể loại âm nhạc theo hướng tương tự như việc xử lý dữ liệu dạng bảng trong dự đoán giá nhà, vốn được mô tả chi tiết trong tài liệu tham khảo với việc áp dụng kỹ thuật Feature Engineering nâng cao. Điều này cho phép chúng tôi xây dựng các biến số có ý nghĩa hơn về mặt mô hình hóa thay vì chỉ dựa hoàn toàn vào dữ liệu gốc. Các đặc trưng âm học như speechiness, instrumentality hay liveness đều mang tính phân loại mạnh mẽ và có thể được biến đổi thành các biến phân loại rời rạc giúp mô hình tuyến tính cũng như mô hình cây quyết định dễ dàng học được ranh giới giữa các thể loại.

2 Phương pháp đề xuất

2.1 Tổng quan vấn đề

Bài toán phân loại thể loại âm nhạc được định nghĩa là việc gán nhãn một đoạn âm thanh vào một trong các lớp thể loại (ví dụ: Pop, Rock, Jazz, Electronic) dựa trên các đặc trưng âm học trích xuất được. Trong khuôn khổ nghiên cứu này, chúng tôi sử dụng bộ dữ liệu từ competition Music Genre Classification trên Kaggle [1] bao gồm 14,396 mẫu huấn luyện với 11 nhãn phân loại (Class từ 0 đến 10). Dữ liệu đầu vào bao gồm các thuộc tính định lượng mô tả tính chất vật lý của âm thanh (như acousticness, danceability, energy, loudness) và thuộc tính định danh (Artist Name).


Qua phân tích dữ liệu sơ bộ, chúng tôi nhận diện ba thách thức chính ảnh hưởng trực tiếp đến hiệu năng của các mô hình cơ sở:

Sự không đồng nhất và nhiễu của dữ liệu: Một số đặc trưng như duration tồn tại dưới nhiều đơn vị đo lường khác nhau (phút và mili-giây), trong khi các trường thông tin quan trọng như key và instrumentality chứa nhiều giá trị thiếu.

Phân phối dữ liệu lệch: Biến duration và một số đặc trưng năng lượng có phân phối lệch phải (right-skewed), gây khó khăn cho các mô hình tuyến tính hoặc các thuật toán dựa trên khoảng cách.

Sự chồng chéo không gian đặc trưng: Các thể loại nhạc khác nhau thường chia sẻ nhiều đặc điểm âm học tương đồng (ví dụ: nhạc Pop và Electronic đều có năng lượng cao), khiến ranh giới phân loại trở nên mờ nhạt nếu chỉ dựa vào dữ liệu thô.

Mục tiêu của nghiên cứu là xây dựng một hệ thống phân loại có khả năng trích xuất các đặc trưng tiềm ẩn từ dữ liệu thô và tổng hợp tri thức từ nhiều thuật toán khác nhau để tối đa hóa độ chính xác dự báo.



Hình 1: Phương pháp đề xuất tổng thể

2.2 Quy trình Tiền xử lý

Quy trình tiền xử lý được thiết kế nhằm chuẩn hóa dữ liệu và loại bỏ các yếu tố nhiễu có thể ảnh hưởng đến quá trình huấn luyện. Đối với các thuộc tính định lượng xuất hiện giá trị thiếu, phương pháp điền trung vị được sử dụng vì khả năng chống chịu tốt trước các giá trị ngoại lai và sự lệch phân phối. Riêng đặc trưng *duration* được chuẩn hóa về đơn vị mili-giây, đồng thời áp dụng biến đổi logarit tự nhiên $\log(1 + x)$ để đưa phân phối về trạng thái gần chuẩn, qua đó cải thiện tính ổn định cho mô hình.

Các trường mang tính chất định danh nhưng không đóng góp cho bài toán phân loại, chẳng hạn như *Id* hay *Track Name*, được loại bỏ hoàn toàn. Việc loại bỏ này vừa giúp giảm chiều dữ liệu, vừa tránh gây nhiễu cho các thuật toán vốn nhạy cảm với các biến không liên quan. Sau toàn bộ các bước xử lý, tập dữ liệu thu được có phân phối ổn định và sẵn sàng cho quá trình trích xuất đặc trưng nâng cao.

2.3 Kỹ thuật Tạo đặc trưng (Feature Engineering)

Trong bối cảnh dữ liệu âm nhạc chứa nhiều chiều thông tin phức tạp, kỹ thuật tạo đặc trưng đóng vai trò trung tâm giúp tăng khả năng phân tách giữa các lớp. Từ bộ đặc trưng gốc, chúng tôi tiến hành xây dựng các đặc trưng phái sinh nhằm mô tả rõ hơn bản chất âm học của từng bài hát.

Trước hết, trường *Artist Name* được mã hoá bằng phương pháp Frequency Encoding. Phương pháp này phản ánh tần suất xuất hiện của nghệ sĩ trong tập dữ liệu, qua đó gián tiếp biểu diễn phong cách hoặc xu hướng sản xuất âm nhạc đặc trưng của từng nghệ sĩ.

Tiếp theo, biến *speechiness* được rời rạc hóa thành ba nhóm dựa trên các ngưỡng được xác định từ hành vi thính học: nhóm âm nhạc thuần túy, nhóm bài hát thông thường và nhóm bài hát có tỷ lệ lời nói cao. Sự phân chia này giúp mô hình phân biệt rõ hơn giữa Pop, Rap, nhạc cụ hoặc Podcast, những thể loại vốn có mức độ chồng lấn cao về tín hiệu.

Các đặc trưng nhị phân khác cũng được xây dựng từ quan sát dữ liệu. Biến “Is Instrumental” được xác định dựa trên giá trị *instrumentalness*, phản ánh mức độ sử dụng nhạc cụ trong bài hát. Biến “Is Live” được tạo dựa trên *liveness*, cho biết khả năng bài hát được thu trực tiếp. Đây là các đặc trưng quan trọng vì bản thu live và bản thu studio thường có cấu trúc năng lượng hoàn toàn khác nhau. Cuối cùng, đặc trưng *Popularity* được phân nhóm thành năm mức nhằm giảm nhiễu từ phân phối lệch và làm cho mô hình dễ dàng học các ngưỡng giá trị hơn.

2.4 Mô hình đề xuất

Để giải quyết các thách thức nêu trên, chúng tôi đề xuất một kiến trúc học máy tích hợp (Ensemble Learning Architecture) dựa trên kỹ thuật Stacking (Stacked Generalization) [2]. Mô hình đề xuất được thiết kế theo cấu trúc hai tầng nhằm tận dụng sự đa dạng của các giả thuyết học máy:

Tầng 0 (Base Learners). Bao gồm một tập hợp các thuật toán học máy mạnh mẽ và đa dạng về cơ chế học:

(1) Gradient Boosting (CatBoost [3], XGBoost [4], LightGBM): Nhóm thuật toán này xây dựng mô hình theo phương pháp tuần tự (sequential), tập trung vào việc giảm độ lệch (bias) và sửa chữa sai số của các cây quyết định trước đó. Chúng đặc biệt hiệu quả trong việc xử lý dữ liệu bảng không đồng nhất.

(2) Bagging (Random Forest, Extra Trees): Nhóm thuật toán này xây dựng các cây quyết định song song và độc lập, giúp giảm phương sai (variance) và hạn chế hiện tượng quá khớp (overfitting) thông qua cơ chế lấy mẫu ngẫu nhiên.

Tầng 1 (Meta-Learner). Chúng tôi sử dụng Logistic Regression làm bộ tổng hợp. Đầu vào của tầng này là các xác suất dự báo (prediction probabilities) từ các mô hình Tầng 0. Nhiệm vụ của Meta-learner là học cách gán trọng số tối ưu cho từng mô hình cơ sở để đưa ra quyết định phân loại cuối cùng, khắc phục điểm yếu của từng mô hình đơn lẻ.

2.5 Chi tiết triển khai

Toàn bộ quy trình thực nghiệm được xây dựng và triển khai trên nền tảng ngôn ngữ lập trình Python, sử dụng hệ sinh thái các thư viện mã nguồn mở hàng đầu về học máy. Cụ thể, thư viện Scikit-learn đóng vai trò nòng cốt trong việc xây dựng đường ống xử lý (pipeline) và đánh giá mô hình, kết hợp với các thư viện chuyên biệt hiệu năng cao như XGBoost, LightGBM và CatBoost cho các thuật toán Gradient Boosting. Quy trình huấn luyện được thiết kế chặt chẽ qua các bước sau:

Thiết lập Pipeline chuẩn hóa: Để đảm bảo tính nhất quán và ngăn chặn hiện tượng rò rỉ dữ liệu (data leakage), mỗi mô hình cơ sở được tích hợp trong một đường ống xử lý khép kín. Trước khi đưa vào huấn luyện, dữ liệu được chuẩn hóa thông qua kỹ thuật RobustScaler. Khác với các phương pháp chuẩn hóa thông thường dựa trên trung bình và phương sai, RobustScaler sử dụng trung vị và khoảng tứ phân vị (Interquartile Range - IQR). Cách tiếp cận này giúp mô hình bền vững hơn trước các giá trị ngoại lai (outliers), vốn xuất hiện thường xuyên trong các đặc trưng biên độ âm thanh.

Tối ưu hóa Siêu tham số (Hyperparameter Tuning): Thay vì sử dụng tìm kiếm lưới (Grid Search) tốn kém tài nguyên, chúng tôi áp dụng chiến lược Tìm kiếm ngẫu nhiên (RandomizedSearchCV) để tinh chỉnh các tham số quan trọng. Quá trình này được thiết lập với số lần lặp là 20 ($n_iter=20$), cho phép thăm dò hiệu quả không gian tham số rộng lớn của các mô hình phức tạp như CatBoost hay Random Forest để tìm ra cấu hình tối ưu nhất.

Chiến lược Kiểm định chéo (Cross-Validation): Để đánh giá khách quan hiệu năng dự báo và khả năng tổng quát hóa, nghiên cứu sử dụng phương pháp kiểm định chéo phân tầng (*Stratified K-Fold*) với hệ số $K = 5$. Chiến lược phân tầng đảm bảo rằng tỷ lệ phân bố của 11 nhãn thể loại nhạc được duy trì đồng nhất giữa các tập huấn luyện (training set) và kiểm thử (validation set) trong mỗi lần lặp. Điều này đặc biệt quan trọng để tránh sai lệch đánh giá trong bài toán phân loại đa lớp.

Cấu hình Stacking: Mô hình Stacking cuối được xây dựng bằng `StackingClassifier`. Các mô hình cơ sở sau khi được tối ưu hóa sẽ đóng vai trò là đầu vào cho tầng Meta-learner. Tại tầng này, chúng tôi sử dụng Hồi quy Logistic (`LogisticRegression`) với số vòng lặp tối đa là 1000 ($max_iter=1000$) để tổng hợp các tín hiệu dự báo và đưa ra quyết định phân loại cuối cùng.

3 Thí nghiệm và kết quả

3.1 Thiết lập thí nghiệm

Để đảm bảo tính khách quan và khả năng tái lập của kết quả, quy trình thực nghiệm được thiết lập với các thông số cấu hình cụ thể như sau:


Môi trường: Python 3.x, thư viện Scikit-learn, XGBoost, LightGBM, CatBoost.

Tiêu chí đánh giá (Metric): Độ chính xác (*Accuracy*) được sử dụng làm thước đo chính đo tính trực quan trong bài toán phân loại đa lớp.

Phương pháp kiểm định: Sử dụng kiểm định chéo phân tầng (*Stratified K-Fold Cross-Validation*) với $K = 5$. Phương pháp này chia dữ liệu thành 5 phần, trong đó mỗi phần giữ nguyên tỷ lệ phân bố các lớp (thể loại nhạc) như tập dữ liệu gốc. Kết quả cuối cùng là trung bình cộng của 5 lần chạy, kèm theo độ lệch chuẩn (*Std*) để đánh giá mức độ ổn định của mô hình.

3.2 Kết quả mô hình cơ sở (Baseline)

Trong giai đoạn đầu, chúng tôi huấn luyện 5 mô hình với bộ tham số mặc định để thiết lập mức chuẩn (*baseline*). Hình 2 và Bảng 1 trình bày chi tiết hiệu năng của các mô hình này.



Hình 2: Phân phối độ chính xác kiểm định chéo của 5 mô hình Baseline

Kết quả cho thấy các mô hình thuộc họ Gradient Boosting (CatBoost, LightGBM) thể hiện ưu thế vượt trội so với các mô hình Bagging (Random Forest, Extra Trees). Cụ thể, CatBoost đạt độ chính xác trung bình cao nhất và độ biến động thấp, cho thấy tính ổn định cao trên các tập dữ liệu con khác nhau.

Bảng 1: Độ chính xác (Accuracy) của các mô hình cơ sở trên tập kiểm định chéo

Mô hình	Accuracy (Mean)	Std
CatBoost	0.5515	0.0054
LightGBM	0.5497	0.0072
XGBoost	0.5379	0.0066
Random Forest	0.5286	0.0074
Extra Trees	0.5250	0.0037

3.3 Kết quả mô hình sau tinh chỉnh tham số (Tuned Models)

Giai đoạn tối ưu hóa sử dụng kỹ thuật `RandomizedSearchCV` để tìm kiếm không gian tham số tốt hơn. Kết quả thực nghiệm tại Bảng 2 cho thấy sự thay đổi đáng kể về thứ hạng các mô hình.

Đáng chú ý, **XGBoost** đã có sự bứt phá ngoạn mục, tăng **3.28%** độ chính xác và vươn lên vị trí dẫn đầu. Điều này minh chứng rằng XGBoost rất nhạy cảm với các siêu tham số (như `learning_rate`, `max_depth`) và có khả năng khái quát hóa tốt nếu được cấu hình đúng. Ngược lại, LightGBM giảm nhẹ hiệu năng, cho thấy bộ tham số mặc định của thư viện này đã được tối ưu khá tốt cho các tác vụ tổng quát hoặc không gian tìm kiếm ngẫu nhiên chưa bao phủ vùng tối ưu cục bộ của nó.

Bảng 2: So sánh độ chính xác CV và kết quả Kaggle sau khi tinh chỉnh

Mô hình	Best CV	Cải thiện	Public Score	Private Score
XGBoost	0.5707	+3.28%	0.57539	0.57500
CatBoost	0.5688	+1.73%	0.57420	0.57870
Random Forest	0.5555	+2.69%	0.54365	0.55833
Extra Trees	0.5488	+2.38%	...	...
LightGBM	0.5456	-0.41%	...	...

3.4 Kết quả mô hình Stacking Ensemble

Mô hình cuối cùng là sự kết hợp của cả 5 mô hình đã tối ưu (Tầng 0) thông qua meta-learner là Logistic Regression (Tầng 1). Cơ chế này cho phép hệ thống học cách gán trọng số tin cậy cho từng mô hình con dựa trên độ tự tin của dự báo.

Kết quả tại Bảng 3 cho thấy mô hình Stacking đạt độ chính xác kiểm định chéo là **58.45%**. So với mô hình đơn lẻ tốt nhất (XGBoost), kỹ thuật Stacking đã cải thiện thêm xấp xỉ **1.4%**. Đây là mức tăng ý nghĩa trong các bài toán phân loại có độ nhiễu cao, khẳng định rằng việc tổng hợp các "giả thuyết yếu"(weak learners) đa dạng có thể tạo ra một "giả thuyết mạnh"(strong learner) với khả năng chịu lỗi tốt hơn.

Bảng 3: Hiệu năng của mô hình Stacking Ensemble so với mô hình đơn lẻ tốt nhất

Phương pháp	CV Accuracy	Public Score	Private Score
Best Single Model (XGBoost)	0.5707	0.57539	0.57500
Stacking Ensemble	0.5845	0.58809	0.57870

Ghi chú: Cột Public Score và Private Score phản ánh kết quả thực tế trên bảng xếp hạng Kaggle, cho thấy khả năng tổng quát hóa của mô hình trên dữ liệu chưa từng thấy (unseen data).

4 Kết luận

Trong giai đoạn thử nghiệm cơ sở, **CatBoost** cho thấy hiệu năng vượt trội nhờ khả năng xử lý tốt các đặc trưng phân loại. Tuy nhiên, sau quá trình tối ưu hóa siêu tham số, **XGBoost** đã có sự bứt phá mạnh mẽ nhất (+3.28%) và vươn lên dẫn đầu về độ chính xác kiểm định chéo (0.5707). Cuối cùng, kiến trúc **Stacking Ensemble** kết hợp cả 5 mô hình đã đạt kết quả cao nhất (58.45%), chứng minh tính hiệu quả của phương pháp học tổ hợp.

Nghiên cứu cũng đã chứng minh tầm quan trọng của việc kết hợp Feature Engineering chuyên sâu (như tạo đặc trưng *Artist Frequency*, *Speech Category*). Việc tạo ra các đặc trưng phái sinh giúp mô hình "hiểu" dữ liệu tốt hơn là chỉ dùng các chỉ số âm thanh thô.

Hướng phát triển tiếp theo bao gồm việc thử nghiệm các mô hình Deep Learning (như TabNet) và mở rộng việc trích xuất đặc trưng từ dữ liệu âm thanh thô (raw audio signal) thay vì chỉ dựa vào các đặc trưng bảng đã có sẵn.

Tài liệu

- [1] A. Nofal, “Music genre classification.” <https://kaggle.com/competitions/shai-music-genre-classification>, 2022. Kaggle.
- [2] L. Breiman, “Stacked regressions,” *Machine Learning*, vol. 24, no. 1, pp. 49–64, 1996.
- [3] L. Prokhorenkova *et al.*, “Catboost: unbiased boosting with categorical features,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [4] T. Chen and C. Guestrin, “Xgboost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794, ACM, 2016.

A Phụ lục: Chi tiết cấu hình tham số tối ưu

Dưới đây là bảng tổng hợp các giá trị siêu tham số (*hyperparameters*) tốt nhất cho từng mô hình cơ sở, được xác định thông qua quá trình tìm kiếm ngẫu nhiên (RandomizedSearchCV).

Bảng 4: Bộ tham số tối ưu cho các mô hình sau quá trình tinh chỉnh

Mô hình	Tham số (Parameter)	Giá trị (Value)
XGBoost	n_estimators	692
	learning_rate	0.0111
	max_depth	5
	min_child_weight	3
	gamma	0.9936
	colsample_bytree	0.9089
	subsample	0.8845
CatBoost	iterations	956
	learning_rate	0.0947
	depth	4
	l2_leaf_reg	7
	border_count	76
LightGBM	n_estimators	205
	learning_rate	0.0723
	num_leaves	23
	max_depth	10
	min_child_samples	63
	colsample_bytree	0.8650
	subsample	0.6739
Random Forest	n_estimators	341
	max_depth	47
	min_samples_split	15
	min_samples_leaf	4
	max_features	'log2'
	bootstrap	True
Extra Trees	n_estimators	221
	max_depth	37
	min_samples_split	8
	min_samples_leaf	8
	max_features	None
	bootstrap	True