



House Prices: Advanced Regression Techniques

Nguyễn Thái Vinh, Phạm Văn Tuấn, Đặng Nhật Đức, Võ Văn Tuấn

Tổng Quan

Bối cảnh vấn đề:

Thị trường bất động sản là một trong những lĩnh vực quan trọng, nơi giá nhà phụ thuộc vào nhiều yếu tố như vị trí, diện tích, chất lượng xây dựng, và tiện ích xung quanh. Việc dự đoán giá bán nhà chính xác giúp hỗ trợ các nhà đầu tư, môi giới và người mua đưa ra quyết định hiệu quả hơn.

Thách thức:

Xử lý dữ liệu thiếu, nhiễu và không đồng nhất

Xác định đặc trưng quan trọng ảnh hưởng đến giá nhà

Thiết kế feature engineering phù hợp để tăng độ chính xác

Kết hợp nhiều mô hình (ensemble) mà vẫn tránh overfitting

Tối ưu hóa kết quả theo chỉ số Root Mean Squared Log Error (RMSLE)

Mục tiêu:

Mục tiêu của đề tài là dự đoán giá bán nhà một cách chính xác nhất. Đánh giá điểm số bằng Root Mean Squared Error (RMSE) giữa logarithm của giá nhà dự đoán và logarithm của giá nhà thực tế quan sát được.

DATASETS


Nguồn dữ liệu (Data Source)

- Bộ dữ liệu: Ames Housing Dataset
- Nguồn: Kaggle – House Prices: Advanced Regression Techniques
- Tác giả: Dean De Cock (dùng trong giảng dạy Khoa học dữ liệu)
- Số mẫu: 1460 bản ghi (train) và 1459 bản ghi (test)
- Số đặc trưng: 79 biến mô tả chi tiết từng ngôi nhà

EDA (Exploratory Data Analysis)


Bằng cách trực quan hóa dữ liệu bằng biểu đồ, ta dễ dàng quan sát, phân tích dữ liệu để đưa ra những chiến lược xử lý cho phù hợp.

Biến mục tiêu (SalePrice)



Hình 1: Biểu đồ phân bố biến mục tiêu

Top 20 feature có tương quan mạnh nhất



Hình 2: Các biến có tương quan mạnh với SalePrice


Các feature bị thiếu >40%

Biến	Số lượng thiếu	Phần trăm thiếu
PoolQC	2909	99.66%
MiscFeature	2814	96.40%
Alley	2721	93.22%
Fence	2348	80.44%
MasVnrType	1766	60.50%
FireplaceQu	1420	48.65%

Bảng 1: Các đặc trưng có giá trị khuyết cao nhất



PHƯƠNG PHÁP ĐỀ XUẤT



Data Preprocessing

Loại bỏ cột nhiều missing > 80% (PoolQC, Fence, MiscFeature)

Điền giá trị thiếu theo ngữ cảnh

- 'None' cho đặc trưng không tồn tại
- 0 cho diện tích & số lượng
- Median theo Neighborhood cho LotFrontage

Loại bỏ outlier (GrLivArea > 4500)

Feature Engineering

Diện tích tổng hợp

TotalSF

TotalPorchSF

TotalFlrSF

TotalBsmFin

TotalBath

Tỉ lệ diện tích

LotRatio

GarageLotRatio

GarageAreaPerCar

Tuổi

HouseAge

RemodAge

GarageAge

Restoration

Đặc trưng Cờ

Cờ tiện ích

HasGarage

HasBsmFin

HasPool

HasFireplace

HasMiscFeature

HasLowQual

HasMasVnr

HasModernElectric

Condition_any_norm

Cờ trạng thái

IsRemodeled

IsNew

Cờ thiếu tiện ích

Has_Nothing

Transformation & Encoding

1 Chuẩn hóa dữ liệu số (Numeric features)

Xóa các cột tương quan yếu hoặc dư thừa để giảm độ cộng tuyến (ví dụ: GrLivArea, 1stFlrSF, GarageArea, PoolArea, ...).

Áp dụng log transform cho các cột số lệch nhiều (skew > 0.75) để giảm độ lệch và làm dữ liệu gần phân phối chuẩn hơn, bao gồm cả cột mục tiêu SalePrice.

2 Mã hóa dữ liệu phân loại (Categorical features)

Ordinal Encoding: Đối với các biến thứ bậc (như ExterQual, KitchenQual, BsmFinQual ...)

Rare Encoding: Các biến có số lượng unique cao (như Neighborhood, SaleType...)

Cuối cùng, sử dụng One-Hot Encoding và loại bỏ cột đầu tiên (drop_first=True) để chuyển đổi các giá trị phân loại thành dạng số.


Model Training & Ensemble

Các base models: Ridge, Lasso, ElasticNet, Gradient Boosting, XGBoost, LightGBM, CatBoost


Ensemble methods:

- Voting Regressor: Trung bình dự đoán của 3 top models
- Stacking Regressor: Kết hợp 3 top models + meta-model Ridge

Evaluation metric: **RMSE** & **R²** với 5-fold CV



Hình 3: Boxplot cho RMSE



Hình 4: Boxplot cho R²

Final Prediction

Models	RMSE		R ²	
	Mean	Std	Mean	Std
CatBoost	1.147	120	9.117	153
Ridge	1.192	115	9.049	143
Gradient	1.233	117	8.982	152
LightGBM	1.273	90	8.916	127
XGBoost	1.351	88	8.780	127
ElasticNet	2.884	115	4.451	165
Lasso	2.916	118	4.330	140

Bảng 2 So sánh hiệu năng RMSE (tham số mặc định)

Models	RMSE (Mặc định)	RMSE (Đã Tối ưu)	Thay đổi
Lasso	2.916	1.226	Cải thiện 57.9%
ElasticNet	2.884	1.223	Cải thiện 57.6%
XGBoost	1.351	1.213	Cải thiện 10.2%
LightGBM	1.273	1.201	Cải thiện 5.7%
Gradient Boosting	1.233	1.162	Cải thiện 5.8%
Ridge	1.192	1.200	Giảm nhẹ
CatBoost	1.147	1.164	Giảm nhẹ

Bảng 3 So sánh hiệu suất (RMSE) trước và sau khi tối ưu hóa tham số

Kết quả và đánh giá

Đây là kết quả sau khi nộp kaggle

336	Phạm Văn Tuấn		0.12063	32	10h
-----	---------------	--	---------	----	-----

Đánh giá:

Quy trình dự đoán giá nhà từ EDA đến ensemble cho thấy:

Feature Engineering và tiền xử lý giúp mô hình tuyến tính (Ridge) đạt hiệu suất gần bằng các mô hình boosting.

Ensemble các mô hình cơ sở luôn cải thiện kết quả so với model đơn lẻ.

Stacking Ensemble với meta-model đạt hiệu suất cao nhất, chứng tỏ Stacking là kỹ thuật mạnh mẽ cho hồi quy dữ liệu bảng.