

CHALLENGE 2

House Price Advanced Regression Techniques

Đặng Nhật Đức, Phạm Văn Tuấn, Võ Văn Tuấn, Nguyễn Thái Vinh
Khoa Công nghệ thông tin, Đại học Sài Gòn

Tháng 11, 2025

Mục lục

01

Giới thiệu



02

EDA



03

Phương pháp đề xuất



04

Thực nghiệm và Thảo luận



05

Kết luận



1. Giới thiệu

Bối cảnh Dữ liệu: Sử dụng bộ dữ liệu Ames Housing (Iowa, 2006-2010), bao gồm 1460 căn nhà cho tập huấn luyện (Train) và 1459 căn nhà cho tập kiểm tra (Test).

Bài toán: Dự đoán giá bán nhà (biến mục tiêu SalePrice) dựa trên 79 đặc trưng đa dạng (Categorical & Numerical).


Mục tiêu Cuối cùng: Xây dựng mô hình mạnh mẽ, tổng quát hóa tốt để đạt được điểm số RMSE thấp nhất trên Kaggle Public Leaderboard.



1. Giới thiệu

Vấn đề: Dự đoán giá nhà tại khu vực Ames Housing

- **Input:** Dữ liệu đặc trưng của một căn nhà (diện tích, hình dạng, đường sá ,....)
- **Output:** Dự đoán giá trị của căn nhà (USD).



Ứng dụng:

- Ước lượng tài sản thế chấp
- Quy hoạch đô thị
- Phân tích đầu tư
- Nghiên cứu & Phát triển

1. Giới thiệu

Thách thức:

Dữ liệu không đồng nhất và thiếu hụt


Top 5 feature có missing value nhiều nhất

	Column	Num_Null	Percent_Null
0	PoolQC	2909	99.657417
1	MiscFeature	2814	96.402878
2	Alley	2721	93.216855
3	Fence	2348	80.438506
4	MasVnrType	1766	60.500171

Đặc trưng nhiều & đa dạng:

- Số lượng: 79 features
- Phân loại: numerical, categorical, ordinal, temporal,

Mối quan hệ phức tạp




1. Giới thiệu

Thách thức:

Lựa chọn và trích chọn đặc trưng:

- Có tới 79 đặc trưng, xong không phải cái nào cũng hữu ích



Quan hệ phi tuyến tính giữa các đặc trưng:



- Giá nhà không tăng tuyến tính theo diện tích hay số phòng.
- Một căn nhà nhỏ nhưng ở trung tâm có thể đắt hơn nhiều nhà to ở ngoại ô.

Outlier và chênh lệch giá quá lớn:



2. EDA








Phân tích biến mục tiêu Sale Price



Có sự lệch phải rõ rệt ở giá trị của SalePrice

2. EDA

Phân tích ngoại lai (outliers):



➔ **Outliers xuất hiện ở rất nhiều feature khác nhau kể cả SalePrice**

2. EDA

Phân tích biến phân loại và dữ liệu thiếu


Biến	Số lượng thiếu	Phần trăm thiếu
PoolQC	2909	99.66%
MiscFeature	2814	96.40%
Alley	2721	93.22%
Fence	2348	80.44%
MasVnrType	1766	60.50%
FireplaceQu	1420	48.65%

Top các thuộc tính có tỉ lệ missing cao nhất

2. EDA

Phân biệt Thứ bậc và Danh nghĩa:

Biến thứ bậc (Ordinal):





→ Các biến này có mối quan hệ gần như tuyến tính với SalePrice

2. EDA



Phân biệt Thứ bậc và Danh nghĩa:

Biến danh nghĩa (Nominal):



2. EDA

Phân tích tương quan




3. Phương pháp đề xuất

Fill missing data:

Nhóm cột	cách điền
Các cột có ý nghĩa “không có đặc trưng”	“None”
Các cột diện tích hoặc số lượng	0
Cột LotFrontage (chiều rộng lô đất)	median theo nhóm “Neighborhood”
Các cột phân loại khác	mode()

3. Phương pháp đề xuất

Encoding:



3. Phương pháp đề xuất

Label Encoding::


Feature	Cách encoding
Street	"Pave" → 1 "Grvl" → 0
Utilities	Loại bỏ do không có sự khác biệt giữa các row
'LandSlope' 'HouseStyle' 'Condition2' 'RoofStyle' 'RoofMatl' 'Exterior1st' 'Exterior2nd' 'MasVnrType' 'Foundation' 'Heating' 'Electrical' 'Functional' 'GarageType' 'SaleType' 'SaleCondition'	Điền theo phân nhóm theo độ hiếm của nhãn

3. Phương pháp đề xuất

Ordinal Encoding: Ordinal Feature: ExterQual, KitchenQual, BsmtQual, PoolQC...

Giá trị	Ex	Gd	TA	Fa	Po	None
Ảnh xạ	5	4	3	2	1	0

Rare Encoding: Biến danh nghĩa (nominal)



“Rare”

3. Phương pháp đề xuất

Feature engineering:

- Đặc trưng dựa trên Tuổi (Age-based Features)

HouseAge	$\text{YrSold} - \text{YearBuit}$
RemodAge	$\text{YrSold} - \text{YearRemodAdd}$
GarageAge	$\text{YrSold} - \text{GarageYrBlt}$
Restoration	$\text{YearRemodAdd} - \text{YearBuilt.}$

3. Phương pháp đề xuất

Feature engineering:

- Đặc trưng Tổng hợp (Aggregate Features)

TotalSF	TotalBsmtSF + GrLivArea
TotalPorchSF	SUM(OpenPorchSF, EnclosedPorch, 3SsnPorch, ScreenPorch, WoodDeckSF)
TotalFlrSF	1stFlrSF + 2ndFlrSF
TotalBsmtFin	BsmtFinSF1 + BsmtFinSF2
TotalBath	FullBath + BsmtFullBath + 0.5 * (HalfBath + BsmtHalfBath)

3. Phương pháp đề xuất

Feature engineering:

- Đặc trưng Tỷ lệ (Ratios):

LotRatio	$\text{GrLivArea} / \text{LotArea}$
GarageLotRatio	$\text{GarageArea} / \text{LotArea}$
GarageAreaPerCar	$\text{GarageArea} / \text{GarageCars}$

3. Phương pháp đề xuất

Feature engineering:

- Đặc trưng Cờ (Flag Features)

Cờ tiện ích:

- | | |
|------------------|----------------------|
| • HasGarage | |
| • HasBsmt | • HasLowQual |
| • HasPool | • HasMasVnr |
| • HasFireplace | • HasModernElectric |
| • HasMiscFeature | • Condition_any_norm |

Cờ trạng thái:

- IsRemodeled
- IsNew

Cờ thiếu tiện ích:

- Has_Nothing

3. Phương pháp đề xuất

Thu hẹp dữ liệu:

- Xóa các cột tương quan yếu hoặc dư thừa để giảm đa cộng tuyến (ví dụ: GrLivArea, 1stFlrSF, GarageArea, PoolArea, ...).

Log transform:

- Các cột số lệch nhiều ($\text{skew} > 0.75$) để giảm độ lệch và làm dữ liệu gần phân phối chuẩn hơn, bao gồm cả cột mục tiêu SalePrice.

Chia dữ liệu: Tách dữ liệu sau khi gộp lại xử lí

- df_train_processed (có giá trị SalePrice)
- df_test_processed (không có SalePrice)

4. Thực nghiệm và thảo luận

Baseline:

K-Fold Cross Validation: 5 fold

Models	RMSE		R ²	
	Mean	Std	Mean	Std
CatBoost	0.1147	0.012	0.9117	0.0153
Ridge	0.1192	0.0115	0.9049	0.0143
Gradient Boosting	0.1233	0.0117	0.8982	0.0152
LightGBM	0.1273	0.009	0.8916	0.0127
XGBoost	0.1351	0.0088	0.878	0.0127
ElasticNet	0.2884	0.0115	0.4451	0.0165
Lasso	0.2916	0.0118	0.433	0.014

4. Thực nghiệm và thảo luận

Tuning:

Baseline + RandomizedSearchCV


Models	RMSE (Mặc định)	RMSE (Đã Tối ưu)	Thay đổi
Lasso	0.2916	0.1226	Cải thiện 57.9%
ElasticNet	0.2884	0.1223	Cải thiện 57.6%
XGBoost	0.1351	0.1213	Cải thiện 10.2%
LightGBM	0.1273	0.1201	Cải thiện 5.7%
Gradient Boosting	0.1233	0.1162	Cải thiện 5.8%
Ridge	0.1192	0.12	Giảm nhẹ
CatBoost	0.1147	0.1164	Giảm nhẹ

4. Thực nghiệm và thảo luận

Thí nghiệm 1:

Ensemble Trọng số Tối ưu (Weighted Ensemble)

Ridge	Lasso
ElasticNet	XGBost
LightGBM	CatBost
Gradient Boosting	



out of fold



min of
RMSE SUM



Best of model weight


4. Thực nghiệm và thảo luận

Thí nghiệm 1:

Ensemble Trọng số Tối ưu (Weighted Ensemble)

Best of model weight

Model	Trọng số
CatBoost	~0.36
Ridge	~0.3x
Gradient Boosting	~0.17



Best RMSE: 0.1129



4. Thực nghiệm và thảo luận

Thí nghiệm 2:

Ensemble Xếp chồng (Stacking Ensemble)

Cấp 0:

Ridge	Lasso
ElasticNet	XGBost
LightGBM	CatBost
Gradient Boosting	

out of fold

Cấp 1:

Ridge

Best RMSE:

0.1114

4. Thực nghiệm và thảo luận

Tổng kết các thí nghiệm:

Phương pháp	RMSE (Trung bình)	RMSE (Kaggle)
CatBoost (Mô hình cơ sở tốt nhất)	0.1147	0.12337
Ensemble Trọng số Tối ưu (Weighted)	0.1129	0.12089
Ensemble Xếp chồng (Stacking)	0.1114	0.12063

5. Kết luận

- Nghiên cứu này đã trình bày một quy trình toàn diện để dự đoán giá nhà, từ phân tích dữ liệu khám phá (EDA) đến xây dựng mô hình ensemble phức tạp. Chúng tôi đã chứng minh rằng:
- **Kỹ thuật tạo đặc trưng (Feature Engineering)** và tiền xử lý là bước quan trọng nhất, giúp mô hình tuyến tính (**Ridge**) đạt hiệu suất gần như các mô hình boosting.
- Việc kết hợp (**ensemble**) các mô hình cơ sở luôn cho kết quả tốt hơn mô hình đơn lẻ.
- Một mô hình **Stacking Ensemble**, sử dụng một meta-model Cấp 1 để học cách kết hợp các dự đoán **OOF**, đã đạt được hiệu suất dự đoán cao nhất, vượt trội hơn cả mô hình Ensemble Trọng số Tối ưu.
- **Kết quả này khẳng định rằng: trong các bài toán hồi quy dữ liệu dạng bảng, Stacking là một kỹ thuật mạnh mẽ và hiệu quả để tối ưu hóa hiệu suất dự đoán.**



Thanks for
listening

