




CHALLENGE 1

Titanic - Machine Learning from Disaster

Đặng Nhật Đức, Phạm Văn Tuấn, Võ Văn Tuấn, Nguyễn Thái Vinh

Khoa Công nghệ thông tin, Đại học Sài Gòn

Tháng 10, 2025



Mục lục



01

Giới thiệu



02

Các phương pháp liên quan



03

Phương pháp đề xuất



04

Thực nghiệm và Thảo luận



05


Kết luận



1. Giới thiệu

Bộ dữ liệu Titanic:


- Tàu Titanic đã va phải tảng băng trôi và chìm vào ngày 15 tháng 4 năm 1912.
- Hơn 1.500 người thiệt mạng.
- Tỷ lệ sống sót bị ảnh hưởng bởi nhiều yếu tố như giới tính, tuổi tác, hạng vé, ...
- Nghiên cứu các yếu tố ảnh hưởng đến sự sống còn.



1. Giới thiệu

Vấn đề: Dự đoán khả năng sống sót của hành khách trong vụ chìm tàu **Titanic**

- **Input:** Dữ liệu hành khách Titanic (Age, Sex, Ticket, ...)
- **Output:** Dự đoán sống sót (Survived/Not Survived)



Ứng dụng:

- Phân tích lịch sử
- Mô hình hóa rủi ro
- Giáo dục & Đào tạo
- Nghiên cứu & Phát triển

1. Giới thiệu

Thách thức:

Dữ liệu thiếu (Age, Cabin, Embarked, Fare)

	Missing Values	Percent (%)
Cabin	687	77.10
Age	177	19.87
Embarked	2	0.22

Dữ liệu thiếu trên tập train


	Missing Values	Percent (%)
Cabin	327	78.23
Age	86	20.57
Fare	1	0.24

Dữ liệu thiếu trên tập test

Đặc trưng đa dạng:

- Số: Age, Fare, Parch ...
- Phân loại: Embarked, Sex

Phân bố không cân bằng



Mối quan hệ phức tạp


Đặc trưng ẩn (Title, Family Size)

2. Các nghiên cứu liên quan

Mô hình phân loại phổ biến:


- Hồi quy Logistic
 - Đơn giản, dễ hiểu
 - Tối ưu hóa hiệu suất
 - Tập trung đặc trưng quan trọng

Sigmoid Function



Đồ thị hàm Sigmoid

- Cây quyết định/Rừng ngẫu nhiên
 - Xử lý phi tuyến tính
 - Giảm quá khớp (Rừng ngẫu nhiên)
 - Tăng tốc học




Sơ đồ cây quyết định

2. Các nghiên cứu liên quan

Missing Data Imputation:

Điền vào các giá trị bị thiếu (ví dụ Age, Embarked, Fare) bằng các phương pháp như:


- Điền bằng mean, median, mode
- Sử dụng mô hình máy học khác để dự đoán giá trị thiếu (IterativeImputer)



Categorical Encoding:

Chuyển đổi các biến phân loại (ví dụ: Sex, Embarked) thành định dạng số mà mô hình có thể hiểu:

- One-Hot encoding
- Label Encoding
- Ordinal Encoding



2. Các phương pháp liên quan

Feature Engineering:


Tạo ra các đặc trưng mới từ các đặc trưng hiện có để cung cấp thêm thông tin cho mô hình

- $\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$
- IsAlone dựa trên FamilySize ($=1$)
- Title trích xuất từ cột Name

Scaling:

Đưa các đặc trưng về cùng một phạm vi để tránh việc các đặc trưng có giá trị lớn hơn ảnh hưởng nhiều hơn đến mô hình


- Min-Max Scaling
- Standard Scaling
- Robust Scaling




So sánh MinMaxScaler, StandardScaler, RobustScaler

2. Các phương pháp liên quan

Cross validation: Stratified K-Fold, K-Fold






Tuning: Grid Search, Random Search



Ensemble

- Bagging
- Boosting
- Stacking



3. Phương pháp đề xuất

Fill missing value:

Điền giá trị thiếu dựa trên các cột tương quan mạnh


Age:

- Điền bằng mean theo nhóm Pclass, SibSp, Sex
- Sau đó điền các nhóm thiếu bằng mean Age

Fare: điền bằng mean theo nhóm Pclass

Embarked: điền bằng mode

Cabin: điền các giá trị thiếu bằng “Unknown”




3. Phương pháp đề xuất

Feature engineering:

FamilySize = SibSp + Parch + 1



- Đi một mình tỉ lệ sống thấp
- Gia đình từ 3-5 người tỉ lệ sống cao
- Gia đình quá đông tỉ lệ sống thấp



IsAlone: 1 nếu FamilySize = 1
ngược lại = 0

TitleGroup: lấy danh xưng từ Name sau đó gom nhóm


- Mr: đàn ông tỉ lệ chết cao
- Mrs, Miss: phụ nữ tỉ lệ sống cao
- Master: trẻ nhỏ được ưu tiên cứu




3. Phương pháp đề xuất

Feature engineering:

Cabin: lấy kí tự đầu của Cabin




Dữ liệu liên tục: Age, Fare




Binning

AgeBin: [-1, 6, 18, 32, 50, 100]




FareBin: [-1, 30, 100, 600]



3. Phương pháp đề xuất

Preprocessor: Dùng ColumnTransformer để dễ áp dụng vào Pipeline

SimpleImputer	Age, Fare
Standard Scaler	Age, Fare
One-Hot Encoding	Embarked, TitleGroup
Ordinal Encoding	Sex, Cabin



Minh họa cách StandardScaler hoạt động

Đánh giá mô hình:

- Cross-validation bằng KFold
- Đánh giá bằng:


$$\text{Accuracy} = \frac{(TP + TN)}{(TP + FP + TN + FN)}$$

Embarked	C	Q	S
C	1	0	0
Q	0	1	0
S	0	0	1


3. Phương pháp đề xuất

Các mô hình sử dụng


LogisticRegression




LinearDiscriminantAnalysis




SVM



RandomForestClassifier







KNeighborsClassifier



3. Phương pháp đề xuất

Hyperparameter Tuning là quá trình tinh chỉnh các siêu tham số của mô hình học máy để tối ưu hóa hiệu suất.

Ensemble Learning là kỹ thuật kết hợp nhiều mô hình học máy để cải thiện độ chính xác và độ ổn định của dự đoán.



4. Thực nghiệm và thảo luận

- **Dataset:** train=891, test=418
- **Chia dữ liệu:** KFold (5 hoặc 10 fold)
- **Feature:**

	Age	Fare	Embarked	Cabin	Pclass	SibSp	Parch	Sex	Survived	FamilySize	IsAlone	TitleGroup	AgeBin	FareBin
327	36.0	13.0000	S	D	2	0	0	female	1	1	1	Mrs	3	0
385	18.0	73.5000	S	U	2	0	0	male	0	1	1	Mr	1	1
646	19.0	7.8958	S	U	3	0	0	male	0	1	1	Mr	2	0
530	2.0	26.0000	S	U	2	1	1	female	1	3	0	Miss	0	0
549	8.0	36.7500	S	U	2	1	1	male	1	3	0	Master	1	1

4. Thực nghiệm và thảo luận


Baseline

- Train shape (891, 8)
- k_fold: 5


submission_baseline.csv
 Complete · now

0.76794

Model	Mean accuracy	Best score (GridSearchCV)	Kaggle (Accuracy)
LR	0.805825 +/- 0.025845	0,812572971	0,75598
LDA	0.802486 +/- 0.032724	0,80248572	0,76316
KNN	0.726144 +/- 0.017993	0,767666813	0,65550
RF	0.821549 +/- 0.022011	0,842884941	0,76794
SVM	0.675664 +/- 0.028057	0,776655577	0,73206




4. Thực nghiệm và thảo luận

Thực nghiệm 1:

- Preprocessor:
 - categorical_features = ['Embarked', 'TitleGroup']: OneHotEncoder
 - numerical_features = ['Age', 'Fare']: SimpleImputer, StandardScaler
 - ordinal_features = ['Sex', 'Cabin']: OrdinalEncoder
- Train data shape: (891, 19)
- k_fold: 10

Model	Mean accuracy	Best score (GridSearchCV)	Kaggle (Accuracy)
LR	0.818165 +/- 0.043809	0.830486891	0.76794
LDA	0.827141 +/- 0.040333	0.827141074	0.77511
KNN	0.732834 +/- 0.041028	0.769875156	0.67943
RF	0.822634 +/- 0.040266	0.845093632	0.77511
SVM	0.687990 +/- 0.041674	0.812534332	0.77033

Bảng kết quả



4. Thực nghiệm và thảo luận


Thực nghiệm 2: Kết hợp mô hình (Ensemble)

Chuẩn bị dữ liệu

- Tương tự thực nghiệm 1
- Preprocessor: bỏ SimpleImputer
- Train data shape: (891, 17)
- k_fold: 5

Huấn luyện và đánh giá từng mô hình

- LR: LogisticRegression
- LDA: LinearDiscriminantAnalysis
- RF: RandomForestClassifier



Model	Mean accuracy	Best score (GridSearchCV)
LR	0.824926 +/- 0.027996	0.830519113
LDA	0.826044 +/- 0.030114	0.827173435
RF	0.813678 +/- 0.025817	0.837260686

4. Thực nghiệm và thảo luận

Thực nghiệm 2: Kết hợp mô hình (Ensemble)

- **Weighted average** là cách gộp kết quả dự đoán của nhiều mô hình lại với nhau bằng cách tính trung bình cộng gán trọng số (weight) cho từng mô hình theo độ mạnh yếu.
- **Stacking** là cách dùng một mô hình “meta” (meta model) để học cách kết hợp các mô hình base.
- **Soft Voting** là trung bình xác suất dự đoán của nhiều mô hình

Ensemble	Accuracy Score	Kaggle (Accuracy)
Weighted average (LDA, RF, LR)	0.829405	0.78299
Stacking (LDA, RF, LR + LogisticRegression)	0.837262	0.77273
Voting (LDA, RF)	0.821229	0.77990

Trọng số weighted average:

- LDA: 0.45
- RF: 0.3
- LR: 0.25

Stacking meta model:

```
LogisticRegression(  
    C=1.0, penalty='l2',  
    solver='lbfgs', max_iter=2000,  
    random_state=42)
```

Voting:

```
VotingClassifier(  
    estimators=[('lda', lda), ('rf', rf)],  
    voting='soft',  
    weights=[3, 2])
```

5. Kết luận

- **Mô hình dự đoán sống sót Titanic:** Đã xây dựng mô hình dự đoán khả năng sống sót trên tàu Titanic.
- **Phương pháp chính:**
 - **Feature Engineering:** giúp cải thiện đáng kể khả năng dự đoán của mô hình.
 - **Cross-Validation:** đánh giá mô hình tốt hơn, đảm bảo tính tổng quát và độ tin cậy.
 - **Tuning:** tinh chỉnh tham số mô hình phù hợp với bài toán
 - **Ensemble:** kết hợp các mô hình lại để cho ra kết quả tốt hơn
- **Kết quả:** Mô hình đã đạt được độ chính xác 0.78299 với Weighted Average
- **Hướng phát triển tương lai:** Cần tiếp tục khám phá các kỹ thuật feature engineering nâng cao và thử nghiệm các mô hình học máy khác để cải thiện hơn nữa hiệu suất dự đoán.



Thanks for
listening

